



PPGTI3003 - APRENDIZAGEM PROFUNDA

deep learning

PROF. JOSENALDE OLIVEIRA

PROGRAMA DE PÓS-GRADUAÇÃO EM TI (PPgTI) - IMD-UFRN

APRENDIZAGEM PROFUNDA

PROF. JOSENALDE OLIVEIRA



Especialista Datascience e Analytics - ESALQ/USP

Engenheiro de IA (sênior): ASUS Cortex@labCoMU-IMD

Analista de Governança de Dados (pleno):

GOVDATA@Conab@NOCS-IFRN



APRENDIZAGEM PROFUNDA

PROF. JOSENALDE OLIVEIRA

ENSINO:

aprendizagem de máquina - TADS@EAJ@UFRN


fundamentos e técnicas de ciência de dados - TADS@EAJ@UFRN

programação avançada - IA - TECINFO@EAJ@UFRN

maio2022-dez2025 - PPGMECA

(controle adaptativo, sistemas não

lineares, projeto de sistemas embarcados)




OBJETIVOS

A partir da descrição do problema de negócio (requisitos), o discente conseguirá **identificar** o tipo de tarefa de *Machine (Deep) Learning* (ML) (supervisionada, não supervisionada, semi supervisionada, por reforço) bem como a arquitetura **profunda** aplicável, com as etapas do processo (*pipeline*), **avaliando** qualitativamente o modelo (e nível de explicabilidade) de modo a colocá-lo em produção (*deploy*), para posterior **monitoramento**/observação e consequente **atualização**

CONTEÚDO – 30H (2 CR) - 32 aulas de ~50min/cada

Fundamentos de ML e ANN; Arquitetura de ANN e treinamento profundo, *fine-tuning* e *foundation models*; Redes convolucionais; Redes recorrentes e modelos de sequência; Transformers e mecanismo de atenção; **Aplicações** (visão, NLP, predição, geração etc.)

SISTEMAS DE MACHINE LEARNING



O'REILLY*

Projetando Sistemas de Machine Learning

Processo Iterativo para
Aplicações Prontas
para Produção



ALTA BOOKS
EDITORA

Chip Huyen

Fonte: https://mlsysbook.ai/vol1/ml_workflow/ml_workflow.html

REQUISITOS


Embora não haja pré-requisito formal, pressupõe conhecimentos de CIÊNCIA DE DADOS (PPGTI3004), APRENDIZAGEM DE MÁQUINA (PPGTI3001), com utilização de Python e os principais pacotes de manipulação, como NumPy e Pandas (ou Polars)

Agentes, robôs, jogos,
raciocínio baseado em
memória, algoritmos
genéticos, ...

Aplicar métodos
científicos, processar
e armazenar grandes
volumes de dados, ...

ppgti3001: Introdução ao Aprendizado Supervisionado de Máquina; Classificação de Dados: problemas de classificação; Técnicas (algoritmos) de classificação; Métricas de Desempenho; Comitês de classificadores; Aprendizado semi-supervisionado; Teste estatístico; Aplicações.


Redes neurais multilayer,
convolucionais, recorrentes,
long short-term memory
(LSTM), redes de hopfield ...



ppgti3004: definições e temas atuais. Dados tabulares: formatos; atributos e observações; dicionários. Entendendo atributos: tipos; visualização; estatística descritiva; relações. Preparando dados: limpeza; transformações; seleção e extração. Entendendo observações: similaridade; tipos e qualidade de agrupamentos.

Fonte: <https://www.serpro.gov.br/menu/noticias/noticias-2019/democratizando-a-inteligencia-artificial>

The AI Universe



REQUISITOS - EXEMPLO: CERTIFICAÇÃO ML AWS

Domain 2: Exploratory Data Analysis

Task Statement 2.1: Sanitize and prepare data for modeling.

- Identify and handle missing data, corrupt data, and stop words.
- Format, normalize, augment, and scale data.
- Determine whether there is sufficient labeled data.
 - Identify mitigation strategies.
 - Use data labelling tools (for example, Amazon Mechanical Turk).

Task Statement 2.2: Perform feature engineering.

- Identify and extract features from datasets, including from data sources such as text, speech, images, and public datasets.
- Analyze and evaluate feature engineering concepts (for example, binning, tokenization, outliers, synthetic features, one-hot encoding, reducing dimensionality of data).

Task Statement 2.3: Analyze and visualize data for ML.

- Create graphs (for example, scatter plots, time series, histograms, box plots).
- Interpret descriptive statistics (for example, correlation, summary statistics, p-value).
- Perform cluster analysis (for example, hierarchical, diagnosis, elbow plot, cluster size).

REQUISITOS - EXEMPLO: CERTIFICAÇÃO ML AWS

Domain 3: Modeling

Task Statement 3.1: Frame business problems as ML problems.

- Determine when to use and when not to use ML.
- Know the difference between supervised and unsupervised learning.
- Select from among classification, regression, forecasting, clustering, recommendation, and foundation models.

Task Statement 3.2: Select the appropriate model(s) for a given ML problem.

- XGBoost, logistic regression, k-means, linear regression, decision trees, random forests, RNN, CNN, ensemble, transfer learning, and large language models (LLMs)
- Express the intuition behind models.

REQUISITOS - EXEMPLO: CERTIFICAÇÃO ML AWS

Why a 1990s Machine Learning Algorithm Destroys LLMs at Predicting House Prices

Bookmark



Gabriel Quaresma ✓
@joaoGabriel55



Recorded at
RubyConf 2026

Description Speaker Event Schedule

Why a 1990s Machine Learning Algorithm Destroys LLMs at Predicting House Prices

Gabriel Quaresma • Las Vegas, NV, United States • Talk

Held on: July 14, 2026

Published: not published

[Link](#)

[Link - artigo CBIC](#)

REQUISITOS - EXEMPLO: CERTIFICAÇÃO ML AWS

Task Statement 3.3: Train ML models.

- Split data between training and validation (for example, cross validation).
- Understand optimization techniques for ML training (for example, gradient descent, loss functions, convergence).
- Choose appropriate compute resources (for example GPU or CPU, distributed or non-distributed).
 - Choose appropriate compute platforms (Spark or non-Spark).
- Update and retrain models.
 - Batch or real-time/online



PLANO DE CURSO

- Referências

[1] ZHANG A.; LIPTON, Z.C.; LI, M.; SMOLA, A.I. Dive into Deep Learning, Cambridge, 2023. <https://d2l.ai/>

[2] ANTIGA, L. et al. Deep learning with PyTorch, 2nd edition, 2026.

[3] <https://heltonmaia.com/deeplearning/intro.html>



PLANO DE CURSO

- Referências

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. MIT Press, 2016.
www.deeplearningbook.org

GÉRON, A. **Mãos à Obra**: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow, 3. ed. O'Reilly (Alta Books), 2025.

HUYEN, C. **Projetando Sistemas de Machine Learning**: processo iterativo para aplicações prontas para produção. O'Reilly (Alta Books), 2023.

Interpretable ML: <https://christophm.github.io/interpretable-ml-book/>

BROWNLEE, J. <https://machinelearningmastery.com/>

Google Crash Course ML + Documentação TensorFlow/Keras + Documentação PyTorch
<https://developers.google.com/machine-learning/crash-course/neural-networks?hl=pt-br>

PLANO DE CURSO

- Software usado nas aulas
 - [Jupyter Lab](#) + [Python](#)
 - [Google Colab](#)
 - *Extensão Jupyter (Microsoft) para VS Code*
- Fontes de dataset / imageset
 - Open data
 - UC Irvine Machine Learning Repository (<http://archive.ics.uci.edu/ml/>)
 - Kaggle (<https://www.kaggle.com/datasets>)
 - AWS (<https://registry.opendata.aws/>)
 - [Deeplake](#) (<https://datasets.activeloop.ai/docs/ml/datasets/mnist/>), [Roboflow](#)
 - Metaportais
 - Data Portals (<http://dataportals.org>)
 - OpenDataMonitor (<http://opendatamonitor.eu>)
 - Quandl (<http://quandl.com/>) NASDAK
 - Wikipedia (<https://homl.info/9>), Quora (<https://homl.info/10>)
 - <https://dados.gov.br/home>
 - IEEE DataPort, OpenML, ImageNet etc.



GPU (T4)
+ colab

CPU: VM com 12GB RAM/100GB
armaz.

[GPU Tesla 4 \(T4\)](#): 15GB VRAM
GDDR6

[Google TPU](#) v5e-1

kaggle

P100: 30h/semana

T4: idem

TPU v5e-8: 20h (9h
direto)

PLANO DE CURSO



Desempenho De Inferência Da T4

Resnet50



DeepSpeech2



GNMT



Acelerações chip-para-chip GPU-para-CPU | 1 NVIDIA T4 GPU vs. 1 Xeon Gold 6140 CPU

PLANO DE CURSO (2026.2)

- Aulas I/II: 21 e 22.08 (6T2345 - 7M2345)
 - Aulas III/IV: 28 e 29.08
 - Aulas V/VI: 04 e 05.09
 - Aulas VII/VIII: 11 e 12.09
 - Projeto individual com qualquer tipo de tarefa/tema, que utilize arquitetura de redes neurais PROFUNDA e tarefa com a complexidade esperada para o tipo de rede
 - Pode ser (recomendável) alinhado ao seu projeto de mestrado/doutorado
 - Entrega:
 - 1) ML/Data project canvas
 - 2) notebook com passo-a-passo do projeto (células markdown explicativas + código)* - link para Colab, Kaggle etc.
 - 3) link repo github/gitlab
 - 4) vídeo de sua apresentação, máximo 10min, estilo pitch
- OBS: Na apresentação, demonstrar funcionamento das partes essenciais, que cubram os requisitos/casos de teste e arquitetura da solução (rede + pipeline)

Qual o problema a ser resolvido?

1

Churn (perda de clientes) muito alto. A solução proposta usando ML é um modelo para identificar os clientes com maior probabilidade de deixar de serem clientes.

Fontes dos Dados

2

base de dados de clientes ativos e dos clientes perdidos nos últimos 12 meses.

Target

4

Cliente="não" i.e. o algoritmo vai aprender quais os atributos significativos e os pesos correspondentes para prever as prob. de um cliente ativo deixar de ser cliente.

Produtos de Dados

5

Modelo que vai ser aplicado a toda base de clientes ativos e vai resultar numa tabela de clientes e a probabilidade de ele deixar de ser cliente.


Direcionadores PITCH


6

- Qual a oportunidade?
- O que está buscando?
- Quais vantagens do produto de dados?

Principais Atributos (variáveis)

3





<https://www.ownml.co/machine-learning-canvas>



Data Product Canvas

Product Name:

Owner:

Date:

Version:

Problem



Ask the right questions:

- What is the problem?
- Why is it a problem?
- Whose problem is it?
- Why, why and why...?

Data



Ask the right questions:

- Source
- Quality
- Access vs. Availability
- Process / Transformation
- Outputs
- Test / Training / Validation

Solution



Ask the right questions:

- Type (Analytics, ML, IA,)
- What will be the solution?
- Output expected?

KPIs



Ask the right questions:

- How to evaluate the model?
- Which metrics should be used?
- How much uncertainty can we handle with?
- AB Test – How?

Actions



Ask the right questions:

- Which actions will be used?
- Which campaigns?

Hypothesis



Ask the right questions:

- What will be tested?
- What are the expected responses for each of them?
- What should we do from each answer? What strategy should we follow?

Actors



Ask the right questions:

- Who is your client?
- Who are your stakeholders?
- Who is your sponsor?
- Who will use the solution?
- Who will consume the solution?
- Who will be impact with?

Values



Ask the right questions:

- What is the size of your problem?
- What is the baseline?
- What is the uplift / savings?

Risks



Ask the right questions:

- What are the risks?
- What these risks might block?

Performance / Impact



Ask the right questions:

- What is the impact? How to measure it?
- Where you can see this improvement / performance?

Example:

- Increase our customers base;
- Keep it them by Reduce Churn;
- Savings lost revenue + A/B Test;
- Reduce cost of acquisition;



br.linkedin.com/company/dataproductcanvas



Data
Product
Canvas



<https://www.dataproductcanvas.com>

Prof. Leandro Carvalho, PhD



br.linkedin.com/in/leandroscarvalho

REQUISITOS - EXEMPLO DL APLICADO

CS231n: Deep Learning for Computer Vision

Stanford - Spring 2025



Coursework

Prerequisites

- Proficiency in Python
All class assignments will be in Python (and use numpy) (we provide a tutorial [here](#) for those who aren't as familiar with Python). If you have a lot of programming experience but in a different language (e.g. C/C++/Matlab/Javascript) you will probably be fine.
- College Calculus, Linear Algebra (e.g. MATH 19, MATH 51)
You should be comfortable taking derivatives and understanding matrix vector operations and notation.
- Basic Probability and Statistics (e.g. CS 109 or other stats course)
You should know basics of probabilities, gaussian distributions, mean, standard deviation, etc.

<https://cs231n.stanford.edu/>

Teachable Machine

EM TERMOS DE FORMAÇÃO TEMOS VISTO...




Bacharelado em Inteligência Artificial

2019-2024 (1. curso do Brasil)

4o. Período	5o. Período	6o. Período	7o. Período
NBC 64 ARQUITETURA DE COMPUTADORES	64 REDES DE COMPUTADORES	64 INTERNET DAS COISAS	96 PERCEPÇÃO E AÇÃO ROBÓTICA
NBC 64 ÁLGEBRA LINEAR	64 HEURÍSTICAS E MODELAGEM MULTIOBJETIVO	64 PROCESSAMENTO DE LINGUAGEM NATURAL	64 APOIO À TOMADA DE DECISÃO
64 MINERAÇÃO DE DADOS	64 REDES NEURAIS PROFUNDAS	64 APRENDIZADO DE MÁQUINA NÃO SUPERVISIONADO	64 PROCESSAMENTO DE ÁUDIO E VOZ
64 APRENDIZADO DE MÁQUINA SUPERVISIONADO	64 VISÃO COMPUTACIONAL	64 APRENDIZADO POR REFORÇO	32 PESQUISA E INOVAÇÃO
64 PROCESSAMENTO DIGITAL DE SINAIS E IMAGENS	64 COMPUTAÇÃO DE ALTO DESEMPENHO	64 PROCESSAMENTO DE DADOS MASSIVOS	64 OPTATIVA

GPU NVIDIA A100 Tensor Core

Aceleração sem precedentes em todas as escalas



2TB de memória RAM, 30TB de SSD e 8 GPUs do tipo [V100](#) com 80Gb

Inferência de Deep Learning em Tempo Real

A IA soluciona uma ampla variedade de desafios de negócios usando uma gama de redes neurais igualmente ampla. Um excelente acelerador de inferência de IA tem que oferecer não apenas o mais alto desempenho, mas também versatilidade para acelerar essas redes.

A H100 amplia a liderança da NVIDIA com a melhor inferência do mercado, com vários avanços que aceleram a inferência em até 30 vezes e proporcionam a menor latência. Os Núcleos Tensor de quarta geração aceleram todas as precisões, incluindo FP64, TF32, FP32, FP16, INT8 e agora FP8, para reduzir o uso de memória e aumentar o desempenho, mantendo a precisão para LLMs.

SÓ PARA TER UMA IDEIA...



Fases 1 e 2 do Colossus. Fonte: R&D World

100K gpus **H100 HGX** NVIDIA
Colossus - Memphis
 Grok-3



Centro OpenAI - Dallas



MAS TEMOS A IA BRASILEIRA??

meetkai
brasil
set-2025

meetkai

- PBlA: investir em 4 anos R\$ 23 bi (US\$ 4,278 bi)* (25.11.2025)
- EUA (2024): US\$ 109 bi
- CHINA (2024): US\$ 9,3 bi

- Modelo (MK1) com 32B parâmetros com a realidade Brasileira
O Brasil poderia desenvolver um LLM do zero? Sim, mas Alessandro Quattrini explica (CEO): “se fossemos começar do zero, estaríamos conversando só daqui a 10 anos. Oito, pelo menos”.

Modelos de Raciocínio em Português - Primeira IA Soberana do Brasil

MeetKai Brasil é uma empresa brasileira dedicada ao potencial transformador positivo da IA. Nossos modelos **pensam em português brasileiro** e residem inteiramente em solo brasileiro.

Começar



Digite seu prompt aqui...

Desenvolvido por Brasil IA Soberana

Raciocínio em Português

IA que fala nossa língua

Inteligência Reimaginada

Plataforma de IA de classe mundial

Privado e Conforme

LGPD, BACEN, ANVISA - conformidade garantida

Infraestrutura Nacional

Servidores brasileiros, controle brasileiro

EM TERMOS DE FORMAÇÃO TEMOS VISTO...



Bacharelado em Inteligência Artificial

2019-2024 (1. curso do Brasil)

Na Universidade Federal de Goiás, ocorreu a formatura da primeira turma graduada em Inteligência Artificial (mar/24). Todos os 14 alunos já estão contratados e os projetos da turma geraram R\$ 1,5 milhão.

A 5ª turma conta com 40 alunos

SISU 2025 - NOTAS DE CORTE UFG

1. Inteligência Artificial - 811,01
2. Engenharia Software - 799,89
3. Medicina - 798,15
4. Ciência da Computação - 781
5. Direito Matutino - 773,99
6. Direito Noturno - 760,78
7. Sistemas de Informação - 760,44

EM TERMOS DE FORMAÇÃO TEMOS VISTO...

Bacharelado em Inteligência Artificial

2025 -
UFPE, UFAM, UFS, UFAL, UFPB, UFDPAr, UFPR



Treinar DNN para MNIST
com pytorch e rust

Usar Jupyter no
supercomputador

5º Nível		
Estrutura Curricular	Natureza	
IMD1151 - CIÊNCIAS DE DADOS - 60h	Obrigatória	 
IMD3002 - APRENDIZADO DE MÁQUINA SUPERVISIONADO - 60h	Obrigatória	 
IMD3003 - APRENDIZADO DE MÁQUINA NÃO-SUPERVISIONADO - 30h	Obrigatória	 
CH Total: 150h.		
6º Nível		
Estrutura Curricular	Natureza	
IMD1114 - APRENDIZADO PROFUNDO - 60h	Obrigatória	 
CH Total: 60h.		
7º Nível		
Estrutura Curricular	Natureza	
IMD1103 - APRENDIZADO POR REFORÇO - 60h	Obrigatória	 
IMD1107 - PROCESSAMENTO DE LINGUAGEM NATURAL - 60h	Obrigatória	 
IMD1108 - VISÃO COMPUTACIONAL - 60h	Obrigatória	 
IMD1116 - COMPUTAÇÃO DE ALTO DESEMPENHO - 60h	Obrigatória	 
IMD1306 - GESTÃO DE PROJETOS E METODOLOGIAS ÁGEIS - 60h	Obrigatória	 
IMD3004 - IA GENERATIVA - 60h	Obrigatória	 
IMD3005 - MLOPS - 60h	Obrigatória	 
CH Total: 420h.		

PARTE II - ASPECTOS BÁSICOS DE ML

IDENTIFICAR TAREFA ML - exemplo

Concurso docente IMD - IA e IoT - Edital n.69-2024

Considere um sistema de controle de tráfego de veículos de uma cidade inteligente. Esse sistema deverá controlar automaticamente os semáforos de acordo com o **fluxo atual de cada avenida**, de forma a **maximizar os fluxos em todo o tráfego**. Não há um conjunto de dados históricos sobre o fluxo de cada avenida, mas o sistema conhece previamente toda a **malha de avenidas, qual o fluxo atual em cada avenida e quais semáforos estão em cada cruzamento dessas avenidas**. O método de aprendizado mais adequado para esse sistema aprender a temporização de cada semáforo, considerando que não há padrões bem definidos de fluxo de cada avenida é o:

IDENTIFICAR TAREFA ML - outros exemplos

- a) recomendar um livro para cliente em loja online
- b) jogar jogo da velha (*tic-tac-toe*)
- c) categorizar filmes em diferentes tipos
- d) aprender a tocar um instrumento
- e) definir o limite de crédito bancário de um cliente
- f) prever reposição de estoque

MÉTRICAS EM MATRIZ DE CONFUSÃO

Você está desenvolvendo um classificador binário que verifica se determinado inseto nocivo está presente em fotos de armadilhas inteligentes (*smart traps*). Se o modelo detecta o inseto (classe positiva), o entomologista é notificado. **A detecção antecipada deste inseto é crítica para prevenir uma infestação.** Um alarme falso (falso positivo) é fácil de tratar: o entomologista vê a foto que foi classificada incorretamente e a marca como tal. Presumindo um nível aceitável de acurácia, **para qual métrica abaixo este modelo deve ser otimizado?**

1. Revocação
2. Precisão
3. Taxa de Falso Positivo

AVALIANDO MODELOS DE CLASSIFICAÇÃO

MATRIZ DE CONFUSÃO – métricas para além da acurácia

A escolha da(s) métrica(s) mais significativa(s) depende do problema, do balanceamento do conjunto em avaliação, do custo das avaliações incorretas

[1] **Acurácia:** o quanto o classificador acertou, seja da classe positiva, seja da classe negativa.


No caso do SPAM, quantos e-mails foram classificados corretamente?

Um modelo perfeito teria 0FN e 0FP com acurácia 100%

É contudo métrica bem geral, com suposição de balanceamento

Quando o dataset é desbalanceado ou um dos erros de FN/FP são mais graves (doenças por exemplo), melhor outras métricas ou *weight classes*

		Valor Previsto	
		0	1
Valor Real	0	Verdadeiro Negativo (VN)	Falso Positivo (FP)
	1	Falso Negativo (FN)	Verdadeiro Positivo (VP)



AVALIANDO MODELOS DE CLASSIFICAÇÃO

[2] **Acurácia das predições POSITIVAS (precisão/precision)**: proporção de classificações positivas que são realmente positivas. Por exemplo, proporção de imagens classificadas como 5 no MNIST que realmente são imagens de 5s: $P = Vp/(Vp+Fp)$

Fração de e-mails **classificados** como spam que eram realmente spam

MAXIMIZAR precisão: reduzir alarmes falsos, ou seja, falsos positivos
o custo de alarmes falsos é relevante

AVALIANDO MODELOS DE CLASSIFICAÇÃO

[3] **Revocação (recall, sensibilidade, taxa de verdadeiros positivos (TPR), taxa de acerto):**

Em geral usada junto com a precisão, pois é a proporção de instâncias (observações) positivas detectadas corretamente pelo classificador.

FN são positivos reais classificados incorretamente (falhas): $R = Vp/(Vp+Fn)$

Mede a fração de spams que foram corretamente classificados como spam

Também chamada **probabilidade de detecção**.

Maximizar R significa Fn baixo, poucas falhas, o custo de falhas é relevante

AVALIANDO MODELOS DE CLASSIFICAÇÃO

[4] **Especificidade, seletividade ou Taxa de Verdadeiros Negativos:**

Avalia a capacidade do modelo detectar resultados negativos, de modo oposto à sensibilidade: $E = Vn/(Vn+Fp)$

AVALIANDO MODELOS DE CLASSIFICAÇÃO

[5] **Taxa de falso positivo (TFP) ou taxa de queda**: proporção de todos negativos reais que foram classificados incorretamente como positivos, conhecida como **probabilidade de alarme falso**

TFP = 1 - Especificidade: $Fp / (Fp + Vn)$, uma TFP baixa significa Vn alto, ou seja, poucos alarmes falsos

[6] **F1-score**: média harmônica entre precisão e revocação, dá mais importância a valores mais baixos e só será alta se a revocação e precisão forem altas. Bom para comparar classificadores. Para P e R semelhante, F1 semelhante. Senão F1 se aproxima da pior métrica.

$$F1 = 2 \cdot (P \cdot R) / (P + R)$$

A **média aritmética** dá mais peso aos valores grandes.

A **média harmônica** dá mais peso aos valores pequenos. É por isso que o **F1-score** usa a média harmônica: se **Precisão** ou **Recall** for baixo, o F1 também fica baixo (não deixa o valor alto ser mascarado).

NEM SÓ DE CONFUSÃO VIVEMOS, MAS DE CUSTOS...

Computing Cost of Classification problem

Cost Matrix	PREDICTED CLASS		
	$C(i j)$	+	-
ACTUAL CLASS	+	-1	100
	-	1	0

Model M1	PREDICTED CLASS		
ACTUAL CLASS	$C(i j)$	+	-
	+	150	40
	-	60	250

$$\text{Accuracy} = 150 + 250 / 150 + 250 + 40 + 60 = 80\%$$

$$\text{Cost} = 150(-1) + 40(100) + 60(1) + 250(0)$$

$$\text{Cost} = 3910$$

Model M2	PREDICTED CLASS		
ACTUAL CLASS	$C(i j)$	+	-
	+	250	45
	-	5	200

$$\text{Accuracy} = 250 + 200 / 250 + 200 + 45 + 5 = 90\%$$


$$\text{Cost} = 250(-1) + 45(100) + 5(1) + 200(0)$$

$$\text{Cost} = 4255$$


Curvas de performance X prevalência

- Cenário: empresa de seguros, com o objetivo de **detectar fraudes**
 - Em Machine Learning (especialmente em problemas de classificação binária), a **prevalência** é a proporção de amostras positivas presentes em um conjunto de dados
 - A taxa de **prevalência atual é de 0.1** (pode-se imaginar uma relação 1:10)
 - A cada semana entram 25 novos casos. O auditor seleciona **aleatoriamente** 10 casos pois é sua capacidade de trabalho, ou seja, **$10/25=0.4$ (40%)** a capacidade de determinar VP+FN
-
- Você desenvolveu **um modelo de ML para ranquear o top-10 casos** e agora o auditor seleciona os casos que seu modelo indica.
 - Como determinar que seu modelo melhora a prática atual?
 - Se melhora, quanto melhora? **Você então plota o gráfico de performance de sensibilidade X prevalências e o gráfico de performance de precisão X prevalências**
 - A equipe deseja detectar os casos fraudulentos o mais rápido possível. Como provar que seu modelo alcança este objetivo de forma mais eficiente e quantificar esta eficiência?

Curvas de performance X prevalência




--- Perfect model
— Your model
-.-.- Random model (previous practice)



--- Perfect model
— Your model
-.-.- Random model (previous practice)

Curvas de performance X prevalência



https://github.com/josenalde/deeplearning/blob/main/src/prcurve_prevalence.ipynb

- Seu modelo, para prevalência de 0.4, captura ~95% de VP enquanto atualmente é ~41%, e isto sem comprometer precisão, pois atualmente é 10% e seu modelo entrega ~12%
- Para obter 100% de VP, o modelo atual exige 100% de casos auditados. Já seu modelo atinge 100% de VP com 70% de casos rankeados auditados, melhorando 30% o processo

○ QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?


PERGUNTA #1. O gradiente descendente pode ficar empacado em um mínimo local, quando treinamos um modelo de regressão logística?

PERGUNTA #2. Vamos supor que queira classificar as fotos como externas/internas E diurnas/noturnas. Você deve implementar dois classificadores de regressão logística ou um classificador de regressão softmax?

QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?

PERGUNTA #1. O gradiente descendente pode ficar empacado em um mínimo local, quando treinamos um modelo de regressão logística?

R: O gradiente descendente não pode ficar empacado em um mínimo local ao treinar um modelo de regressão logística porque a função de custo é convexa, ou seja, se você desenhar uma linha reta entre quaisquer dois pontos da curva, a linha nunca atravessará a curva.



○ QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?

A função de custo utilizada na regressão logística é a **entropia cruzada binária** (Binary Cross-Entropy Loss), também conhecida como perda logarítmica (**Log Loss**). Ela mede a diferença entre as probabilidades previstas pelo modelo e os rótulos binários reais (0 ou 1).

A função de custo média para um conjunto de dados é dada pela seguinte fórmula: $\mathcal{J}$

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(\sigma(z^{(i)})) + (1 - y^{(i)}) \log(1 - \sigma(z^{(i)}))]$$

Onde:

- m é o número de exemplos de treinamento.
- $y^{(i)}$ é o rótulo real (0 ou 1) para a i -ésima observação.
- $\sigma(z^{(i)})$ é a probabilidade prevista pelo modelo (saída da função sigmoide) para a i -ésima observação.
- $z^{(i)}$ é o resultado da combinação linear das características de entrada e dos pesos ($w^T x^{(i)} + b$). $\mathcal{J}$

Para a área de **Teoria da Informação**, a **entropia** é definida como sendo uma forma de medir o grau médio de incerteza a respeito de fontes de informação, o que consequentemente permite a quantificação da informação presente que flui no sistema.

QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?

A regressão logística utiliza a função sigmóide, que produz saídas entre 0 e 1, interpretadas como probabilidades. A função de custo de erro quadrático médio, comumente usada na regressão linear, não é ideal para a regressão logística porque resultaria em uma **função de custo não convexa** com muitos mínimos locais, dificultando a otimização pelos algoritmos como o gradiente descendente. A **função de entropia cruzada binária é convexa**, o que garante que o algoritmo de otimização (como o gradiente descendente) encontre o mínimo global (ou seja, os melhores parâmetros do modelo).



A fórmula para calcular a entropia cruzada discreta para N classes é:

$$H(p, \hat{p}) = - \sum_{i=1}^N p(i) \cdot \log(\hat{p}(i))$$

Onde:

- $p(i)$ é a probabilidade real (verdadeira) da classe i .
- $\hat{p}(i)$ é a probabilidade estimada (prevista) da classe i .
- O logaritmo ($\log$) é tipicamente o **logaritmo natural** ($\ln$, ou $\log_e$), mas pode ser $\log_2$ ou $\log_{10}$, dependendo da convenção. Para este cálculo, usaremos o logaritmo natural ($\ln$).

QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?




QUE REGR. LOGÍSTICA E SOFTMAX TEM EM COMUM?

PERGUNTA #2. Vamos supor que queira classificar as fotos como externas/internas E diurnas/noturnas. Você deve implementar dois classificadores de regressão logística ou um classificador de regressão softmax?

R: uma vez que não são classes exclusivas (ou seja, todas as quatro combinações são possíveis), basta treinar dois classificadores de regressão logística

Multi-Class Classification with NN and SoftMax Function



$$\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ \vdots \\ z_K \end{bmatrix} = \begin{bmatrix} \mathbf{w}_1^\top \\ \mathbf{w}_2^\top \\ \mathbf{w}_3^\top \\ \vdots \\ \mathbf{w}_K^\top \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix}$$

The softmax as

$$\sigma(j) = \frac{\exp(\mathbf{w}_j^\top \mathbf{x})}{\sum_{k=1}^K \exp(\mathbf{w}_k^\top \mathbf{x})} = \frac{\exp(z_j)}{\sum_{k=1}^K \exp(z_k)}$$

This will result in a normalization of the output adding up to 1, interpretable as a probability mass function.