



APRENDIZADO PROFUNDO

deep learning

PROF. JOSENALDE OLIVEIRA

PROGRAMA DE PÓS-GRADUAÇÃO EM TI (PPgTI) - UFRN

VÁRIAS VISÕES SOBRE “APRENDER”

aprender

a·pren·der

vtd e vint

1 Ficar sabendo, reter na memória, tomar conhecimento de: “Então o Botelho [...] não perdoava a ninguém, amaldiçoando todo aquele [...] que gozava o que ele não desfrutara; que sabia o que ele não aprendera” (AA1). “– Pede então à Rita que to ensine... [...] não terá muito que aprender!” (AA1).

vtd e vint

2 Adquirir habilidade prática (em): “Eu, quando comecei a tocar violão, não queria aprender música...” (LB2). Os chimpanzés aprendem com rapidez espantosa.

vtd, vti e vtdi

3 Passar a compreender (algo) melhor graças a um depuramento da capacidade de apreciação, empatia, percepção etc.: “– Nunca vi uma criatura para aprender as coisas com tanta facilidade!” (AA2). Aprendeu muito com os próprios erros. Aprenderam dos amigos a ausência nas horas difíceis.

ETIMOLOGIA

lat *apprehendere*, como *esp.*

“AM é o campo de estudo que possibilita aos computadores a habilidade de aprender **sem explicitamente programá-los**”

[Arthur Samuel, 1959] – Ver história do OCR

*aplicação de AM disseminada na década 90: filtro spam

“O AM é uma abordagem para **aprender padrões complexos** (supondo que existem) a partir de dados existentes e usar esses padrões para fazer **predições sobre dados desconhecidos**”

[Chip Huyen, 2023]

“Um programa de computador aprende pela experiência E em relação a alguma tarefa T e alguma medida de desempenho P SE o seu desempenho em T, conforme medido por P, melhora com a experiência E”

[Tom Mitchell, 1997]

Fonte: Michaelis

**Como uma criança aprende que
ambos são dinossauros?**



E aqui?





Descreva textualmente esta cena

Na imagem, vemos um cão de porte médio aparecendo através de uma abertura em um tronco de árvore oco. A madeira é grossa, envelhecida e cheia de texturas naturais, com rachaduras e marcas do tempo.

O cachorro, de pelagem branca com manchas pretas, tem o rosto alegre e expressivo: olhos atentos e brilhantes, orelhas levantadas e a boca aberta em um sorriso canino, mostrando que parece estar feliz ou curioso. Suas patas dianteiras também surgem pelo buraco, apoiadas na borda interna do tronco, como se ele estivesse confortavelmente encaixado ali.


Ao fundo, há um ambiente natural — possivelmente uma floresta — com vegetação desfocada, reforçando a sensação de um momento espontâneo e divertido durante um passeio ao ar livre.

DALL-E (image_gen.text2im)

O backbone interno do DALL-E moderno:

- Ele usa uma **arquitetura baseada em UNet** (típica de **modelos de difusão**)
- Mas com **blocos Transformer** (2017, Google Brain) integrados dentro do UNet. Transformou PLN com mecanismo de **auto atenção**.
- E utiliza **atenção espacial** e **atenção cruzada** com o texto
- Os blocos de atenção geralmente são implementações inspiradas em **Vision Transformers (ViT)**, mas **não é um ViT puro**.

DALL-E ARCHITECTURE



Segmentação Panóptica da Cena (gpt5.1)

Instâncias (objetos individuais)

1. Cachorro

- Classe: *animal*
- Tipo: instância única
- Posição: em cima de um galho principal da árvore
- Aparência: porte médio, pelagem branca, língua para fora (parece ofegante ou animado)

Regiões de fundo (stuff)

2. Árvore principal

- Classe: *árvore/tronco*
- Tipo: região
- Ocupa o centro da imagem
- Possui três grandes ramificações formando um “Y”, onde o cachorro está apoiado

2. Outras árvores ao fundo

- Classe: *árvore/vegetação*
- Tipo: regiões
- Distribuídas no plano de fundo em diferentes distâncias
- Folhagem verde, luz filtrada

3. Grama / cobertura do solo

- Classe: *grama*
- Tipo: região
- Estende-se por quase toda a parte inferior da imagem
- Áreas de sombra e sol alternadas

4. Céu (parcialmente visível)

- Classe: *céu*
- Tipo: região
- Visível entre as copas das árvores
- Iluminação clara

APRENDIZADO “DE” MÁQUINAS (tipo) - Busca por padrões





Ser humano estabelece **conexões** para lidar com coisas novas

Similaridade pode ser óbvio para o humano, mas não para computadores

Máquinas operam sobre **tarefas frequentes**, com alto volume e velocidade


Desafio: máquinas (serem ensinadas e depois) ‘aprenderem sozinhas’

APRENDIZADO “DE” MÁQUINAS (tipo) - Busca por padrões




Todas as placas STOP precisariam ser reconhecidas, independente do seu estado
segmentação panóptica (2018) - veículos autônomos



UMA REDE NEURAL “RASA” FARIA ISTO?





ARQUITETURAS PROFUNDAS (EFFICIENTPS)




ARQUITETURAS PROFUNDAS (ViT)




ARQUITETURAS PROFUNDAS (CNN)




VISÃO COMPUTACIONAL
You Look at Once (YOLO (2016))




EXEMPLOS CLÁSSICOS



MNIST KERAS - Exemplo DNN Keras




FASHION MNIST




<https://www.kaggle.com/datasets/paramaggarwal/fashion-product-images-dataset>

FUNDAMENTOS DE ML

Um filtro de spam baseado em ML aprende automaticamente quais palavras e frases são bons indicadores de spam, ao detectar os padrões de palavras inusitadamente frequentes em exemplos de SPAM quando comparado aos exemplos corriqueiros (HAM). Se surge novas palavras em e-mails marcados como SPAM pelos usuários, começa a marca-los sem a intervenção do desenvolvedor



Abordagem com ML



FUNDAMENTOS DE ML



Conjunto de treinamento inclui as soluções desejadas (rótulos/labels)

Tenta aprender sem um professor

Insuficiência de rótulos
Misto de técnicas

[Saiba mais]

Agente deve aprender sozinho qual é a melhor estratégia (política), para obter o maior número de recompensas ao longo do tempo

[Jaguar (RL)
BELBIC-Josena
Idé]

<https://deepmind.google/technologies/alphago/>


FUNDAMENTOS DE ML - FOCO NAS FEATURES

Anderson, E. The Irises of the Gaspé Peninsula. Bulletin of the American Iris Society, 59, 2-5, 1935.

Fisher, R.A. The use of multiple measurements in taxonomic problems. Annals of Eugenics, 7, 179-188, 1936,

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica



iris setosa



petal sepal

iris versicolor



petal sepal


iris virginica



petal sepal

BY PRAMOD SAHU


Iris Data (red=setosa, green=versicolor, blue=virginica)




FUNDAMENTOS DE ML - FOCO NOS ALGORITMOS

□ Aprendizado baseado em instâncias

- O sistema aprende os exemplos por meio da memorização e depois generaliza em novos casos, ao empregar uma medida de similaridade a fim de compará-los a outros exemplos aprendidos (ou um conjunto deles)




- ○ K-vizinhos mais próximos (KNN) é um dos modelos preditivos mais simples que existe, pois não possui premissas matemáticas e não é custoso computacionalmente. Requer apenas uma noção de distância e uma premissa de que pontos que estão perto uns dos outros são similares!



$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p} \text{ for } p \geq 1$$




```
from scipy.spatial import distance
x = [3,6,9]
y = [1,0,1]
print(distance.euclidean(x,y))
print(distance.cityblock(x,y))
print(distance.minkowski(x,y,p=3))
```



FUNDAMENTOS DE ML - FOCO NOS ALGORITMOS

Métodos mais comuns: KNN, SVM, Árvore de Decisão, Redes Neurais (MLP!)

```
from sklearn.tree import DecisionTreeClassifier
classifier = DecisionTreeClassifier()
classifier.fit(X_train, y_train)
```



Understanding the risks to prevent a heart attack.

<https://www.datacamp.com/community/tutorials/decision-tree-classification-python>

FUNDAMENTOS DE ML - REGRESSÃO



□ Aprendizado baseado em modelo

□ Modo de generalização de um conjunto de exemplos com um modelo matemático para fazer previsões

- A tarefa de regressão, também chamada de predição ou estimação, ocorre quando o atributo alvo da base de dados que se deseja aprender possui valor contínuo, como o preço de uma casa ou o lucro de uma empresa
- Nesse caso, o algoritmo de aprendizado de máquina deve encontrar um modelo matemático (equação) capaz de mapear as entradas numa saída esperada
- Tipo especial de regressão: **série temporal!!!**
- Tipo especial de regressão: problemas de contagem

FUNDAMENTOS DE ML - REGRESSÃO



- ❑ Um bom projeto de ML tem boa capacidade preditiva
- ❑ Acurácia nas decisões (acertos)
- ❑ Performance preditiva! Nem sempre a interpretação do processo é simples (pois decisões envolvem processos complexos)
- ❑ Em Inferência (regressão por exemplo), a relação entre as variáveis é melhor interpretável, mas usualmente pior performance preditiva




Regressão/Inferência: target quantitativo
Classificação: target qualitativo
Regressão logística: target quantitativo é probabilidade de um evento ocorrer como função de outros fatores.

AGRUPAMENTO

- A tarefa de agrupamento busca reunir os exemplos por similaridade, criando grupos que serão posteriormente rotulados pelo cientista de dados
- Redução de dimensionalidade (simplificar dados sem perder muita informação) – merge de features correlacionadas (Feature Extraction - Selection)
- Detectar anomalias







Fonte: <https://arxiv.org/pdf/1301.3666>



□ **Agrupamentos: não supervisionado – maximizar semelhanças (minimizar distâncias) dentro do cluster e maximizar diferenças (maximizar distâncias) entre clusters**

Método K-means (incluindo Fuzzy c-means) é o mais usado

**Mas existem vários outros métodos e variantes:
Hierárquicos, aglomerativos, incremental etc.**



ASSOCIAÇÃO

transações


TID	Items
1	pão, leite
2	pão, fralda, cerveja, ovos
3	leite, fraldas, cerveja, coca
4	pão, leite, fraldas, cerveja
5	pão, leite, fraldas, coca

Exemplos de regras de associação



$\{\text{fraldas}\} \rightarrow \{\text{cerveja}\},$
 $\{\text{leite, pão}\} \rightarrow \{\text{ovos, coca}\},$
 $\{\text{cerveja, pão}\} \rightarrow \{\text{leite}\},$

Implicação significa co-ocorrência, e não causa!!!

- Também chamado de mineração de regras de associação
- Essa tarefa busca **identificar padrões** nos dados analisados, como ocorrências de valores juntos em um mesmo exemplo da base
- No exemplo a seguir, espera-se que o algoritmo encontre os itens que normalmente são adquiridos juntos (filtragem colaborativa - filtragem de conteúdo moderno)



OUTRA PERSPECTIVA: ML X DL - Models...



Goodfellow, I et. al (2016)


OUTRA PERSPECTIVA: ML X DL - Models...

Representação de conhecimento

Como detectar carros em imagens?

- rodas?
- Embora com forma geométrica definida, mas pode haver sombras, reflexo do sol em partes metálicas, outro objeto sobrepondo uma parte etc
- representações apreendidas permitem (em geral) melhor desempenho que representações “escritas à mão”
- permitem maior adaptação a situações novas com o mínimo de intervenção humana
- a dificuldade em IA prática são os fatores de variação: exemplos - idade de uma pessoa, sexo, sotaque, palavras ditas; posição do carro; cor; ângulo e brilho do sol etc; escrever features com estas considerações é difícil; um carro vermelho (pixel) pode parecer mais preto à noite; a silhueta do carro depende do ângulo de visada

UMA ARQUITETURA BASE PARA APRENDER REPRESENTAÇÃO




Um autoencoder é um **tipo de rede neural artificial** usada para aprender uma representação comprimida (codificada) dos dados de entrada de forma **não supervisionada**. Ele funciona treinando a rede para reconstruir seus próprios dados de entrada, forçando a informação a passar por um "gargalo" (bottleneck) dimensional (espaço latente)

- Codificador (Encoder): Pega os dados de entrada e os comprime em uma representação de dimensão inferior, chamada de espaço latente.
- Decodificador (Decoder): Pega a representação do espaço latente e tenta reconstruir os dados de entrada originais a partir dessa representação comprimida.
- A versão variacional (VAE) pode gerar dados novos **semelhantes** ao dado de treinamento

OUTRA PERSPECTIVA: ML X DL - Models...

E estas representações precisam ser “SIMPLES”, transformadas




Goodfellow, I et. al (2016) - desenhe uma linha separando estas classes

OUTRA PERSPECTIVA: ML X DL - Models...

Aprendizado profundo se baseia em separar e analisar relações entre as partes, seja por abordagem hierárquica, seja pelo sequenciamento (posicional)

Goodfellow, I et. al (2016) - ideia de hierarquia de detalhes (menor - maior)



OUTRA PERSPECTIVA: ML X DL - Models...

Experimento de 2012 da Google ao apresentar 10 milhões de vídeos do YouTube (1 frame de cada vídeo 200x200) com a seguinte pergunta: como você vê o mundo?

[Peter Norvig, 2012 - YouTube](#)



OUTRA PERSPECTIVA: ML X DL - Models...

Experimento de 2012 da Google ao apresentar 10 milhões de vídeos do YouTube (1 frame de cada vídeo 200x200) com a seguinte pergunta: como você vê o mundo?


[Peter Norvig, 2012 - YouTube](#)



OUTRA PERSPECTIVA: ML X DL - Models...

Experimento de 2012 da Google ao apresentar 10 milhões de vídeos do YouTube (1 frame de cada vídeo 200x200) com a seguinte pergunta: como você vê o mundo?

[Peter Norvig, 2012 - YouTube](#)



OUTRA PERSPECTIVA: ML X DL - Models...

Experimento de 2012 da Google ao apresentar 10 milhões de vídeos do YouTube (1 frame de cada vídeo 200x200) com a seguinte pergunta: como você vê o mundo?


[Peter Norvig, 2012 - YouTube](#)



OUTRA PERSPECTIVA: ML X DL - Models...



Experimento de 2012 da Google ao apresentar 10 milhões de vídeos do YouTube (1 frame de cada vídeo 200x200) com a seguinte pergunta: como você vê o mundo?

[Peter Norvig, 2012 - YouTube](#)




OUTRA PERSPECTIVA: ML X DL - Models...


Recent breakthroughs in AI have not only increased demand for AI products, they've also lowered the barriers to entry for those who want to build AI products. The model-as-a-service approach has transformed AI from an esoteric discipline into a powerful development tool that anyone can use. Everyone, including those with minimal or no prior AI experience, can now leverage AI models to build applications. In this book, author Chip Huyen discusses AI engineering: the process of building applications with readily available foundation models.



MUDANÇA DE PERSPECTIVA: uso e personalização



Hugging Face



VAMOS DAR UMA OLHADA EM NOSSA BASE: AS REDES NEURAIS

continua...

